

CAHIER DES CHARGES

KOUMA AI

Chatbot conversationnel en langues locales — Baoulé & Dioula

Version 1.0

23 septembre 2026

Équipe projet : [Nom des 6 membres à compléter]

Encadreur : [Nom à compléter]

1. Contexte et présentation du projet

Le baoulé et le dioula sont deux langues parlées quotidiennement par des millions de personnes en Côte d'Ivoire, mais quasiment absentes des outils numériques actuels. La grande majorité des services conversationnels (chatbots, assistants) ne fonctionnent qu'en français ou en anglais, ce qui exclut de fait les locuteurs qui s'expriment principalement dans leur langue locale.

Le projet KOUMA AI vise à combler une partie de ce manque en développant un chatbot capable de converser en baoulé et en dioula, accessible via une API et intégrable à d'autres applications. Le projet est réalisé par une équipe de six personnes sur une durée d'un mois, dans le cadre d'un projet encadré.

« Kouma » signifie « parole / parler » dans les langues mandingues (dont le dioula) — un nom qui résume l'ambition du projet : donner une voix numérique aux langues locales.

2. Objectifs du projet

2.1 Objectif général

Concevoir et livrer, en un mois, un prototype fonctionnel de chatbot conversationnel capable d'interagir en baoulé et en dioula, exposé via une API REST et intégrable à une application tierce existante.

2.2 Objectifs spécifiques

- Permettre un échange textuel bidirectionnel en baoulé et en dioula.
- Construire un pipeline de traduction automatique français ↔ baoulé et français ↔ dioula.
- Connecter ce pipeline à un moteur de génération de réponses (LLM) pour produire des réponses pertinentes.
- Exposer le service via une API REST documentée, prête à être consommée par d'autres applications.
- Réaliser l'intégration du chatbot dans au moins une application .

3. Périmètre du projet (MVP à 1 mois)

3.1 Inclus dans le périmètre

- Conversation textuelle uniquement (hypothèse à valider avec l'encadreur — voir § 3.3).
- Reconnaissance vocale (Speech-to-Text) et synthèse vocale (Text-to-Speech) en baoulé/dioula.
- Conversation à domaine totalement ouvert, sans restriction thématique
- Traduction français ↔ baoulé et français ↔ dioula sur le vocabulaire du domaine retenu.
- Une API REST avec au minimum un point d'entrée de conversation.
- Une intégration démontrée sur une application tierce.

3.2 Hors périmètre (pistes pour une phase 2)

- Domaine d'usage restreint et défini avec l'encadreur (ex. FAQ, service d'information ciblé) plutôt qu'une conversation totalement ouverte.
- Prise en charge d'autres langues locales additionnelles.
- Modèle « natif » entraîné depuis zéro en baoulé/dioula sans utiliser le français.

4. Approche technique retenue

4.1 Principe : pipeline de traduction assisté par un LLM

Compte tenu du délai d'un mois et de la rareté des ressources numériques en baoulé et en dioula, le projet retient une architecture en pipeline plutôt qu'un modèle « natif » entraîné directement sur ces langues. Le principe : traduire l'entrée vers le français, laisser un modèle de langage déjà performant en français produire la réponse, puis retraduire cette réponse vers la langue d'origine.

4.2 Étapes du pipeline

- L'utilisateur envoie un message en baoulé ou en dioula .
- Identification de la langue source (indiquée par l'utilisateur ou détectée automatiquement).
- Traduction automatique du message vers le français (modèle de traduction — MT).
- Génération de la réponse en français par un modèle de langage (LLM).
- Traduction automatique de la réponse vers la langue source.
- Renvoi de la réponse traduite à l'utilisateur.

4.3 Avantages et limites à documenter

Cette approche est réaliste dans le délai imparti : elle s'appuie sur des modèles de traduction existants ou fine-tunables, et sur la qualité conversationnelle d'un LLM déjà mature en français. En contrepartie, la qualité globale dépend directement de celle de la traduction automatique — qui reste un exercice difficile pour des langues aussi peu dotées — avec un risque de contresens. L'équipe prévoit donc une validation humaine systématique des traductions clés par des locuteurs natifs avant mise en production (voir §5.3 et §11).

5. Données nécessaires et sources identifiées

5.1 Besoins en données

- Corpus parallèles français ↔ baoulé (paires de phrases traduites).
- Corpus parallèles français ↔ dioula, ou à défaut bambara (langue très proche, intercompréhensible).
- Lexiques bilingues complémentaires pour combler les lacunes de vocabulaire du domaine retenu.

5.2 Ressources externes déjà identifiées

Ressource	Langue	Contenu	Source
Baule speech dataset (data354)	Baoulé	~565 enregistrements audio + transcriptions	Zenodo
Common Voice – Baoulé (bci)	Baoulé	~15h de parole, 16 locuteurs, audio + texte	Mozilla Common Voice
Common Voice – Dioula (dyu)	Dioula	Corpus audio, volume encore limité	Mozilla Common Voice
Bayèlèbabaga	Bambara (proche du dioula)	~47 000 lignes parallèles bambara-français	RobotsMali / HuggingFace/bamadaba
Corpus Griots	Bambara	30h d'entretiens transcrits et traduits en français	RobotsMali / INALCO
Corpus de sentiment en bambara	Bambara	Texte annoté, utile pour la compréhension d'intention	Recherche académique (arXiv)

Le dioula et le bambara appartiennent à la même famille de langues manding et sont largement intercompréhensibles : les ressources bambara peuvent servir de base de travail, à adapter et valider par des locuteurs dioula de Côte d'Ivoire.

6. Spécifications fonctionnelles de l'API

6.1 Points d'entrée envisagés

Endpoint	Méthode	Description
/chat	POST	Reçoit un message utilisateur (texte, langue, identifiant de session) et renvoie la réponse du chatbot dans la même langue.
/translate	POST	Traduction ponctuelle d'un texte, sans passage par le LLM conversationnel.
/languages	GET	Liste des langues actuellement supportées par le service.
/health	GET	Vérification de la disponibilité du service.

6.2 Authentification et format

- Authentification par clé API propre à chaque application cliente.
- Échanges au format JSON, avec des codes de réponse HTTP explicites en cas d'erreur.
- Documentation générée automatiquement (Swagger/OpenAPI) pour faciliter l'intégration.

7. Intégration avec des applications tierces

- Fournir des exemples de requêtes prêts à l'emploi (curl, Python, JavaScript).
- Prévoir, éventuellement, un mécanisme de webhook pour les intégrations asynchrones.
- Réaliser et valider l'intégration sur au moins une application réelle

8. Organisation de l'équipe (6 membres)

Pôle	Responsabilités principales	Membre(s)
Collecte et annotation des données	Constitution des corpus, coordination avec les locuteurs natifs, validation linguistique	[Aicha]
Traduction automatique / NLP	Choix et adaptation des modèles de traduction, évaluation de la qualité	[Syndoux]
Backend & API	Développement de l'API REST, authentification, documentation technique	[Falibeta]
Intégration LLM & pipeline	Connexion traduction ↔ LLM ↔ traduction, tests bout-en-bout	[Kadi]
Intégration et tests	Intégration à l'application tierce, tests fonctionnels	[Ivan + Ezé]
Documentation et coordination	Suivi du planning, documentation, préparation des présentations	[Syndoux + Ezé + Kadi]

9. Planning prévisionnel (4 semaines)

Semaine	Objectifs
Semaine 1	Cadrage avec l'encadreur, choix du domaine d'application, inventaire et collecte des ressources existantes, mise en place de l'environnement technique.
Semaine 2	Constitution et nettoyage du corpus, premiers tests de traduction automatique, développement du squelette de l'API.
Semaine 3	Intégration du pipeline complet (traduction → LLM → traduction), tests de bout en bout, collecte complémentaire avec les locuteurs natifs.
Semaine 4	Intégration à l'application tierce, corrections, documentation finale, préparation de la présentation.

10. Livrables attendus

- Le présent cahier des charges, validé par l'encadreur.
- Une API fonctionnelle et documentée.
- Un chatbot démonstrateur intégré à une application existante.
- Un rapport final et un support de présentation.

11. Contraintes et risques identifiés

Risque	Mitigation envisagée
Rareté des données en baoulé et en dioula	Réutilisation des corpus bambara existants + collecte ciblée avec les locuteurs disponibles.
Absence d'orthographe standardisée pour ces langues	Définition d'une convention d'écriture propre au projet, documentée dans le rapport final.
Délai très court (1 mois)	Périmètre volontairement restreint : domaine fermé, texte uniquement, phase 2 explicitement identifiée.
Qualité incertaine de la traduction automatique	Validation humaine systématique par des locuteurs natifs avant toute mise en production.

12. Critères de validation du prototype

- Le chatbot répond correctement à un pourcentage cible [à définir avec l'encadreur] des questions test, en baoulé comme en dioula, sur le domaine retenu.
- L'API répond dans un délai acceptable [seuil à définir avec l'encadreur].
- L'intégration avec l'application tierce fonctionne de bout en bout, sans erreur bloquante.
- Les réponses du chatbot sont validées qualitativement par au moins deux locuteurs natifs par langue.

13. Ressources nécessaires

- Quatres (04) PC gamers
- Un abonnement Claude Pro